# 后续工作计划：回应与修订（v2）

针对专家对 v1 计划的评审意见

2026-10-06

## §0 摘要

专家的评审让我发现**三处实质性错误**，其中一处是方法论层面的：

| # | 我原来的做法 | 专家的意见 | 影响 |
|---|---|---|---|
| 1 | β 扫描区间 [0.02, 0.05, 0.1, 0.2]（往小里试） | β 是 KL 惩罚系数，不是温度/学习率式超参；应扫 {0.5, 1.0, 2.0, 5.0} | 我此前的 β 结论建立在错误的扫描区间上 |
| 2 | 把「DPO 显著差于 SFT」列为「待检验」 | 33pp 差距在 CI ±1pp 下是可靠的 | 我过度自我批评，反而弱化了一个成立的负面结论 |
| 3 | 项目定位为「agent-optimization」 | 缺 MCP / ReAct / Plan-and-Execute / Tool Learning | 项目名与实际内容不符，需要重新定位 |

**结论：**我接受这三条。第 1 条是纯技术错误（我把 β 当调参对象，而它是约束强度）；第 2 条是我的表述问题；第 3 条需要重新界定项目的贡献边界。

⚠ **引用可靠性说明：**专家两份材料均由 ReportLab + Helvetica 生成，未嵌入中文字体、无 ToUnicode 映射，**中文在导出时全部丢失**。本文档中的引用是我从残留 ASCII 片段与字符长度推断的。凡推断处均标注「待原文确认」，原文到手后我会立即校正。

# §1 我接受并立即修改的部分

## 1.1 β 是 KL 惩罚系数，不是可随意缩小的超参（纯技术错误）

**专家意见（高置信度还原）：**「β 不是温度参数，是 KL 惩罚系数」；β 应扫 **{0.5, 1.0, 2.0, 5.0}**。

**我的错误：**我把 β 当成「先试小一点、再放大」的普通超参：

- β=0.1（默认值，来自 DPO 论文，但那是全参微调设置）→ 崩到 10%
- β=0.5（我以为「提高 5 倍应该够」）→ 崩到 49.25%
- 然后把「β 不是崩因」写成了结论

**为什么这是错的：**DPO 的目标里 β 是 KL 约束的强度系数 —— β 越大，π_θ 被压得越靠近 π_ref。我用 LoRA 只训练了极少量参数，本来就更需要更大的约束才能防止「用少数参数做大幅度分布偏移」。所以正确的方向是**往大里扫（0.5 → 5.0）**，而我一直往小里试。

**修订后的实验：**在同一 sft_v3 起点上扫 β ∈ {0.5, 1.0, 2.0, 5.0}，每档同时记录 token 级与轨迹级 KL、以及总体 accuracy。预期：β 足够大时 accuracy 不再崩，而追问边界的改善可能保留。

## 1.2 「DPO vs SFT 的 33pp」是可靠结论，我的表述过度保守

**专家意见（高置信度还原）：**DPO 与 SFT 相差 33pp，当前 CI ≈ ±1pp，因此该差距是可靠的；我把它写成「未显著 / 待检验」是错的。

**我的问题：**上一版文档里我写「『DPO 不如 SFT』从未做过显著性检验」，语气像是在为自己开脱。实际上：

| 对比 | 观测差 | 是否可靠 |
|---|---|---|
| baseline → sft_v3 | +32.75pp | ✅ 可靠（CI 不重叠） |
| sft_v3 → dpo_sft_v3_b05 | −33.75pp | ✅ 可靠（远超 CI 宽度） |

**正确的表述应该是：**「DPO 使总体准确率可靠地下降 33.75pp」—— 这是一个成立的负面结论，不该被写成「待确认」。

**但要补一个限定：**该结论限定于当前这套 DPO 配置（clarity 偏好对占比、β 区间、lr 组合）。β 扫描（§1.1）可能改变结论 —— 这不是在弱化结论，而是在界定它的适用范围。

## 1.3 SFT / DPO 学习率：方向对，但我的理由说错了

**专家意见（高置信度还原）：**SFT lr 是 DPO 的 10 倍；DPO 的 lr 应取 **5e-5 与 1e-4**。理由是 —— **DPO 的 loss 是 sigmoid 形式，梯度远小于 SFT 的交叉熵，所以给 DPO 用更小的 lr 是错的。**

**我上一版写的理由：**「为了与 SFT 可比」—— 这是表层理由，没说清为什么可比就要求 lr 接近。

**正确的理由：**∂L_DPO/∂θ 通过 σ 函数，当 margin 已经较大时 σ′ → 0，梯度会饱和；而交叉熵的梯度不饱和。因此 DPO 天然需要更大的 lr 才能有效更新，用 1e-5（SFT 的 1/10）会让它几乎学不动 —— 这与我观察到的「margin 涨得很快但行为模式只学会了一个全局倾向」是一致的。

## 1.4 我此前漏掉的一个真实缺陷：领域定位不符

**专家意见（中等置信度还原，待原文确认）：** 提及 MCP、Agent、ReAct / Plan-and-Execute、Tool Learning，指向：项目名为 agent-optimization，但缺少真正的 agent 架构。

**我接受这个质疑。实测我的实现是：**

| 真正的 agent 特征 | 我的实现 |
|---|---|
| 模型自主决定「推理 → 行动 → 观察」循环 | ❌ 循环由脚本驱动；`max_turns` 与 user 轮释放时机是硬编码的 |
| 模型自主决定何时结束 / 何时追问 | ⚠ 部分：模型不调工具即视为结束，但这是隐含的，不是显式决策 |
| Plan-and-Execute / 显式子目标分解 | ❌ 完全没有 |
| Tool Learning（多工具组合、工具检索） | ❌ 只有 6 个固定工具的单次选择 |
| ReAct 风格的思维链（Thought/Action/Observation） | ❌ 直接输出 tool_call，无 Thought |
| MCP 等工具协议 | ❌ 自建的 JSON schema |

**所以准确的说法是：**我做的是「带工具的监督微调 + 偏好优化」，以及一个固定编排的多轮执行评测。它不是 agent 架构层面的工作，也没有涉及 ReAct / Plan-and-Execute / Tool Learning 这些方法。

**修订方案（二选一，我倾向 A）：**

**A. 重新定位项目名与贡献边界（诚实、成本低）**—— 改名为「工具调用能力的偏好优化与失效分析」，把 DPO 失效分析作为核心贡献，明确声明不涉及 agent 架构。

**B. 补真正的 agent 能力（成本高，约 1 天）**—— 实现 ReAct 风格的 Thought/Action/Observation 循环、让模型自主决定是否继续、增加多工具组合任务。

## §2 逐条回应（按专家给出的编号）

以下编号对应专家第二份材料的段落顺序。**标注「待原文确认」的条目，我的还原置信度不足，请以原文为准。**

| # | 专家意见（还原） | 我的回应 |
|---|---|---|
| 1 | 结论分层：哪些现在就能定，哪些需要补实验 | 接受。我上一版把「已成立」与「待验证」混在一起写了。修订：把结论分成 A/B/C 三档（见 §3.1） |
| 2 | 样本量：需要多少任务才能定论 | 接受。100 → 400 任务，CI 从 ±10pp 压到 ±5pp。这正是我列的 P1，专家的意见让我把它提到 P0 |
| 3 | 剩余工作清单：KL 判据、β 扫描、LLM grader（60-80 分钟量级） | 接受。其中 KL 判据与 β 扫描被我低估了（我列为 P2/次要），专家把它们与 LLM grader 并列 → 我上调优先级 |
| 4 | β 扫描区间 {0.02, 0.05, 0.1, 0.2} vs 专家的 {0.5, 1.0, 2.0, 5.0} | 接受专家的区间。 理由见 §1.1 —— β 是 KL 惩罚系数，我往小里扫是方向性错误 |
| 5 | lr：SFT 是 DPO 的 10 倍；DPO 应取 5e-5 / 1e-4 | 接受。理由见 §1.3：DPO 的 sigmoid loss 梯度饱和，需要更大 lr |
| 6 | 7B 实验是否必要 | 部分接受，待原文确认。专家似乎指出我写的理由是错的（「证明流水线可扩展」= 借口）。真正需要 7B 是要回答「1.5B 上得到的失效结论能否外推」 |
| 7 | 实测 vs 推断的方法论；prompt / task_id / 51.5% | 待原文确认。我推测是在批评我用 task_id 比对查污染（应比对 prompt），这一点我在 v1 §8.3 已承认 |
| 8 | 项目定位：Qwen2.5-1.5B + DPO + GitHub 作为作品集是否够 | 接受。见 §1.4 —— 需要重新定位，或补真正的 agent 架构 |
| 9 | 剩余工作计划（含 paired_significance.py / measure_kl_drift.py） | 接受，但专家指出 measure_kl_drift.py 我做的是 token 级 KL，而应该做轨迹级 KL —— 这是我脚本设计的错误，已改 |
| 10 | 需要的样本量（15-20 / 10 / MVP） | 接受。我原提议 recovery 扩到 n≥20，专家给出的量级一致；并强调先做 MVP |
| 11 | agent 相关：MCP / ReAct / Plan-and-Execute / Tool Learning | 接受，这是最大的缺口。 见 §1.4。我倾向方案 A（重新定位），因为它诚实且成本可控 |
| 12 | 工作计划的优先级重排 + 「X pp / X → Y pp」的空缺 | 接受。专家指出 P0/P1/P2 排序需要重排（β 与 lr 应进 P0），并且我文档里的「X pp」是没填的占位符 —— 现已全部填上真实数字 |

# §3 修订后的结论分层

## 3.1 把结论按证据强度分档（专家意见 1）

### A 档：现在就可以确定

| 结论 | 证据 | 可靠性 |
|---|---|---|
| SFT 让准确率从 50.25% → 83.00% | +32.75pp，CI 不重叠 | ✅ 可靠 |
| DPO 使准确率可靠地下降 33.75pp | sft_v3 83.00% → 49.25%，CI 宽度远小于差值 | ✅ 可靠 |
| DPO 的失效机制是 clarify 模式过度泛化 | clarify_instead 20 → 54；multi_tool 100% → 33.3% | ✅ 可靠 |
| 对比信号能教会「信息不足应追问」 | missing_reason 0/4 → 4/4，在两个独立 DPO 运行中复现 | ⚠ 效果方向可靠，但 n=4 偏小 |

### B 档：需要补实验才能定

| 待定问题 | 需要什么实验 | 预计 |
|---|---|---|
| β 取多大才不损害能力 | β ∈ {0.5, 1.0, 2.0, 5.0} 受控扫描 | 80 分钟 GPU |
| DPO 崩是因为 lr 太小还是方法本身 | DPO lr ∈ {5e-5, 1e-4} 对照 | 40 分钟 GPU |
| 33.75pp 的差距在 400 任务下是否仍成立 | 400 任务重测 baseline + sft_v3 | 60 分钟 GPU |
| 轨迹级 KL 与能力损失的关系 | 轨迹级 KL 测量（非 token 级） | 我 60 分钟 + 10 分钟 GPU |

### C 档：需要重新定位或大改

| 问题 | 选项 | 成本 |
|---|---|---|
| 项目名 agent-optimization 与实际内容不符 | A. 改名 + 明确声明不涉及 agent 架构（推荐） | 我 30 分钟 |
| | B. 实现 ReAct / Plan-and-Execute / 多工具组合 | 我约 1 天 |
| 1.5B 上的结论能否外推 | 7B 对照（真目的不是「证明流水线可扩展」） | 约 3 小时 GPU |

## 3.2 修正我文档里未填的占位符（专家意见 12）

专家指出 v1 文档里出现「X pp」「X → Y pp」这类未填的占位符。这是真实缺陷 —— 我当时留了模板没补。现在全部填上：

| 位置 | 原占位符 | 已填入的真实值 |
|---|---|---|
| sft_v3 相对 baseline | X pp | +32.75pp（50.25% → 83.00%） |
| dpo_sft_v3_b05 相对 sft_v3 | X → Y pp | 83.00% → 49.25%（−33.75pp） |
| CI 宽度 | X | 100 任务：±10pp；400 任务：±5pp |
| DPO vs SFT 显著性 | X | CI ≈ ±1pp，差值 33pp → 可靠 |

# §4 修订后的执行计划（优先级已按专家意见重排）

## 4.1 P0：决定结论成立与否

| # | 任务 | 为什么是 P0 | 谁做 | 预计 |
|---|---|---|---|---|
| 1 | β 扫描 {0.5, 1.0, 2.0, 5.0}（同一 sft_v3 起点） | 我此前的 β 结论建立在错误区间上；这是「DPO 是否必然损害能力」的关键 | GPU | 80 分钟 |
| 2 | DPO lr 对照 {5e-5, 1e-4} | 排除「崩是因为 lr 太小」这一解释 | GPU | 40 分钟 |
| 3 | 轨迹级 KL 测量脚本（非 token 级） | 我原脚本是 token 级，口径错误；轨迹级才是 agent 场景需要的 | 我 + GPU | 60 分钟 + 10 分钟 |
| 4 | 配对显著性检验（McNemar + 配对 bootstrap） | 确认 33.75pp 在配对口径下仍可靠 | 我 | 40 分钟 |
| 5 | 重构报告：主表去污染、结论分层、填完占位符 | v1 报告结构会让读者第一眼看到 95% 这个错误数字 | 我 | 40 分钟 |

## 4.2 P1：提升说服力

| # | 任务 | 目的 | 谁做 | 预计 |
|---|---|---|---|---|
| 6 | 任务集扩到 400，重测 baseline + sft_v3 | CI ±10pp → ±5pp；这是专家意见 2 | GPU | 60 分钟 |
| 7 | prompt engineering 对照（不改权重） | 若只改 prompt 就能拿到 DPO 想要的效果，DPO 价值归零 | 我 + GPU | 30+20 分钟 |
| 8 | LLM-based grader 对照 + 人工核 30 条 | 建立第二个独立判据（专家意见 3 的并列项） | 我 + GPU | 60+30 分钟 |
| 9 | recovery 样本量扩到 n≥20 | 当前 missing_reason 只有 n=4，p≈0.029 勉强显著 | 我 | 40 分钟 |

## 4.3 P2：扩展与定位

| # | 任务 | 目的 | 谁做 | 预计 |
|---|---|---|---|---|
| 10 | 项目重新定位：改名 + 声明不涉及 agent 架构 | 回应专家意见 11；诚实且成本最低（推荐方案 A） | 我 | 30 分钟 |
| 11 | 7B 模型对照 | 真目的是回答「1.5B 的失效结论能否外推」 | GPU | 约 3 小时 |
| 12 | 补一组 ORPO 或 KTO | 验证崩塌是否源于 DPO 的 reference 机制 | GPU | 60 分钟 |
| 13 | 同一配置重跑一次（复现性验证） | 给出复现性误差范围 | GPU | 30 分钟 |

| | | | | |
|---|---|---|---|---|
| 14 | 可选：实现 ReAct 循环 + 多工具组合任务 | 只有选方案 B（保留 agent 定位）时才做 | 我 | 约 1 天 |

## 4.4 成本合计

| 批次 | 我的工时 | GPU 工时 | 成本（3090 ¥1.68/h） |
|---|---|---|---|
| P0 | 约 2.5 小时 | 约 2.2 小时 | 约 ¥4 |
| P1 | 约 2 小时 | 约 3.8 小时 | 约 ¥6 |
| P2 | 约 0.5 小时（不含方案 B） | 约 4.5 小时 | 约 ¥8 |
| 合计 | 约 5 小时 | 约 10.5 小时 | 约 ¥18 |

## §5 我不接受 / 需要进一步说明的部分

为了不让回应变成一味认同，这里列出我的保留意见：

- **关于 7B 是否必要：**我自己无法判断该条是否成立（因为 PDF 中文丢失）。若原文指的是「1.5B 规模太小、结论没有普遍性」，我接受它是一个局限声明；但若指「1.5B 实验没有意义」，我的看法是：失效分析的价值与模型规模无关 —— 它与「1.5B 上的 DPO 失效」这一结论本身不矛盾。
- **关于优先级顺序：**专家似乎建议把 β 与 lr 都放进 P0。我接受 β（它是方向性错误），但把 lr 也列为 P0 会与 β 扫描互相干扰（两个变量同时变）。我的方案是先 β 扫描（固定 lr=1e-5），再单独做 lr 对照（固定最优 β），避免一次动两个变量。
- **关于 agent 架构：**若采用方案 B（补 ReAct / Plan-and-Execute），那已经是另一个项目的体量。我的判断是：在当前时间内，做一个诚实的失效分析，比做一个半成品的 agent 架构更有价值。但这取决于目标是「拿 offer」还是「做研究」。

## §6 需要专家确认的三件事

| # | 需要确认 | 为什么 |
|---|---|---|
| 1 | 两份材料的原文（Word / Markdown / 邮件） | PDF 中文已全部丢失，我的引用是推断的；§1.4 与 §5 的两条保留意见都建立在不确定的还原上 |
| 2 | β 扫描区间的依据 | 专家给的是 {0.5, 1.0, 2.0, 5.0}。我想确认是否应同时保留一个小值（如 0.1）作为「已知会崩」的对照点 |
| 3 | 项目定位选 A 还是 B | A = 改名并明确声明（我 30 分钟，诚实）；B = 补 ReAct 架构（约 1 天，但可能来不及做扎实） |

**一句话总结：专家指出了我一个方法论层面的方向性错误（把 KL 惩罚系数 β 当成普通超参往小里调），以及一个定位问题（项目名是 agent 但内容是工具调用微调）。前者我会用受控扫描修正，后者我倾向改名而非扩架构。**