agent-optimization 项目：后续工作计划

针对问题清单的逐条回应与执行方案

2026-10-06

§0 一页摘要

这份文档回应专家提出的 20 条问题，并给出后续工作的优先级与执行方案。我的总判断：**清单里绝大多数是真问题，其中 3 条是致命的**，需要修正报告与补做实验；另有约 5 条属于「已发现但未清理干净」或「需要新增工作才能回答」。

最重的一条是：**整个项目的叙事目前建立在一个已被我自己判定为污染的数字（SFT 95%）上。**虽然报告里标注了它不可用，但它仍留在主表中，导致任何读者第一眼看到的都是这个错误数字。修复方式是重构报告，主表只保留干净数据。

优先级	事项	工作量	GPU
P0	重构报告：主表只用干净数据，污染数字下沉附录	我 30 分	否
P0	配对显著性检验（McNemar / 配对 bootstrap）+ 功效分析	我 40 分	否
P0	补真实 KL(π_θ || π_ref) 漂移监控（替代 logps/chosen）	我 60 分	10 分
P0	SFT/DPO 超参对齐后重跑（当前 lr 不可比）	—	40 分
P1	任务集扩到 400（CI 从 ±10pp 压到 ±5pp）	—	60 分
P1	prompt engineering 对照（不改权重，只改 prompt）	我 30 分	20 分
P1	β 扫描 [0.02, 0.05, 0.1, 0.2]	—	80 分
P2	agent 评测补齐 flight_search 多轮变体	我 60 分	15 分
P2	LLM-based grader 对照 + 人工一致性	我 60 分	30 分
P2	7B 模型对照（证明流水线可扩展）	—	约 3 小时
P2	W&B 实验追踪接入	我 30 分	否
合计	我自己可完成约 5 小时（无 GPU）	需租用 GPU 约 6 小时	≈ ¥10

§1 项目当前状态（诚实版）

1.1 可信的数字

以下是当前唯一可对外引用的结果（训练数据与评测任务零重合，已脚本验证）：

实验	accuracy	pass^4	格式正确率	数据状态
baseline（原始基座）	50.25%	45.00%	62.25%	—
sft_v2（干净，但语料覆盖不足）	78.75%	77.00%	98.00%	✅ 干净
sft_v3（干净 + 覆盖补全）	83.00%	83.00%	100%	✅ 主结果
dpo_sft_v3_b05（β=0.5，从 sft_v3 出发）	49.25%	40.00%	58.80%	✅ 干净

1.2 已作废的数字（必须明确声明）

下面三组实验的训练数据里混入了评测任务（**1292 / 2509 = 51.5% 的训练样本，其 prompt 与评测 prompt 逐字相同**），因此它们的数字不可用于任何对比，包括「DPO 不如 SFT」这个结论本身。

实验	accuracy	问题
sft_only	95.00%	训练数据含评测任务 → 虚高
dpo_joint	68.50%	同上
dpo_from_sft	10.00%	同上 + β=0.1 崩塌

1.3 agent 多轮评测（sft_v3）

指标	39 个多轮任务	19 个真需工具链	50% 故障注入
轨迹成功率	100.00%	100.00%	89.74%
故障恢复率	—	—	77.78%
工具调用有效率	98.31%	100.00%	100.00%
成功轨迹平均轮数	1.54	2.00	1.71
循环异常率	0.00%	0.00%	0.00%

⚠ **覆盖度局限：**这 39 个任务不含 flight_search 与 weather_advisory，而 flight_search 恰是单轮评测里最弱的类别（68.2%）。因此 100% 只说明「与 agent 循环相关的四个类别全部过关」，不代表模型整体能力。

§2 对专家问题的逐条回应

说明：问题清单 PDF 由 ReportLab 生成，中文字体未嵌入，原文的中文在导出时全部丢失（渲染为占位符），因此以下编号对应的问题描述是**我根据 PDF 中残留的 ASCII 片段推断的，可能有个别误读。**若专家能提供原文，我会修正这张表。

2.1 致命问题（必须修，否则结论站不住）

问题 1｜核心贡献是 DPO，但没有任何 DPO 配置达到统计显著

我的判断：成立，且我在报告里把结论写得比证据强。

- **现状：**我实际只检查过 baseline → sft_v3 这一对的 CI 不重叠；「DPO 不如 SFT」从未做过显著性检验。
- **修复：**对所有组对做配对检验（同一批任务上的 McNemar / 配对 bootstrap），而不是只比较各自 CI 是否重叠——CI 重叠 ≠ 无差异，这一点我做错了。
- **补充：**给出最小可检测效应（MDE）与当前样本量的功效分析，明确「哪些结论在 100 任务下根本无法确认」。

问题 2｜51.5% 污染是自己发现的，但它仍出现在主表里

我的判断：成立。这是最严重的一条，属于我的报告结构问题。

- **现状：**我发现污染、重训了干净模型、拿到了 83%，但把受污染的 95% 继续留在消融报告的表 1 里「作对比」，结果它污染了读者的第一印象。
- **修复：**报告重构——主表只保留干净数据（50.25% / 78.75% / 83.00% / 49.25%）；污染数字下沉到附录，并注明「不可用于任何对比」；报告开头第一段就写主结果，而不是让读者读到 §8 才知道 95% 作废。

问题 3｜三组实验用了同一份被污染的数据，所以「SFT +44.8pp」建立在污染上

我的判断：成立。+44.8pp 是污染版的差值，真实值是 +32.75pp。

- **更正：**sft_only 95.00% → 真实（干净）sft_v3 83.00%；提升幅度 44.8pp → 32.75pp。
- **修复：**所有引用了 +44.8pp / 95% 的地方（消融报告、面试稿、简历条目）全部替换或明确标注。

问题 6｜用 logps/chosen 与 rewards/margins 判断健康，不能替代 KL

我的判断：成立，这是原理性缺陷，而且我已经因此判断错过一次。

- **原因：**DPO 的 KL 约束在 p_θ 与 p_{ref} 的整个分布之间；logps/chosen 只含 $\log \pi_\theta(y_w)$ 单个序列，既不含 π_{ref} 项，也不覆盖整体分布。
- **实测后果：**β=0.5 实验中 logps/chosen 稳定在 −4.55（我据此判断「健康」），而 accuracy 从 83% 崩到 49.25%。

- **修复**：写 measure_kl_drift.py：加载 π_θ（DPO 模型）与 π_ref（SFT 模型），在同一批 prompt 上计算真实的 log-prob 差与逐 token KL，替代目前单序列的判据。

问题 17 | 项目自己的结论是「DPO 是净负贡献」，但表述矛盾

我的判断：成立。我的报告里同时写了正贡献与负贡献，却没给统一判断。

维度	证据	量级
正贡献	missing_reason_corrected：SFT 0/4 → DPO 4/4	+1 个错误模式、4 个样本
负贡献	总体 accuracy：83.00% → 49.25%	−33.75pp（−135 个样本）

明确结论：**净负贡献。用 4 个样本的改善换 135 个样本的损失，不划算。**

2.2 真问题，但属于「已发现未清理」或「需新增工作」

问题 4 | chosen/rejected 构造可能有问题（拒答 / 澄清类）

- **现状**：部分成立，而且是本次 β=0.5 失效的直接原因。CLARIFY 偏好对教的是「信息不足时追问」，模型把这个模式泛化过头，在信息充足、本该动手的任务上也改成追问（clarify_instead 20 → 54；multi_tool 100% → 33.3%；booking_flow 72.2% → 16.7%）。
- **方案**：偏好对只告诉模型「A 比 B 好」，没有告诉它「A 在什么条件下比 B 好」。修复方向是构造条件化偏好数据（在输入里显式标注信息是否充分），而不是继续增加同类偏好对。

问题 5 | β 从 0.5 试到 0.1，但 β 单因素未被隔离

- **现状**：我已做过否证实验，但不够受控。

实验	β	起点	accuracy	起点是否相同
dpo_from_sft	0.1	sft_only（污染模型）	10.00%	❌
dpo_sft_v3_b05	0.5	sft_v3（干净模型）	49.25%	❌

- **修复**：仅 2 个点，且起点模型不同，不能构成 β 的受控比较。需补 β 扫描 [0.02, 0.05, 0.1, 0.2]，全部从同一个 sft_v3 出发。

问题 8 | SFT 与 DPO 的学习率不同，比较不公平

实验	lr	epochs	batch	LoRA
SFT（sft_v3）	1e-4	2	2 × 8	r=16 / α=32
DPO（dpo_sft_v3_b05）	1e-5	1	2 × 8	r=16 / α=32

- **判断**：成立。SFT 的 lr 是 DPO 的 10 倍。虽然两者的优化目标不同，lr 本来就不该完全相同，但当前差距过大，无法排除「DPO 崩是因为 lr 太低/太高」这一解释。
- **修复**：把 DPO 的 lr 提到 5e-5 与 1e-4 各跑一次，与现有的 1e-5 形成三点对照。

问题 9｜任务集分布严重不均衡（easy 27 / medium 12 / hard 61）

- **判断**：成立。hard 占 61%，而 sft_v3 的 hard 准确率只有 73.8%，整体 accuracy 被 hard 类主导。按难度分组的结论（如「medium 比 hard 高」）受类别混杂影响。
- **修复**：在报告里明确声明难度标签是按类别赋的、不是按任务实际难度测的；分组结论只作参考，不作为因果推断。

问题 10｜grader 是 rule-based，没有 LLM-based 对照与人工一致性

- **判断**：成立，这是评测效度的缺口。当前所有数字都来自一个规则评分器，没有第二判据。
- **修复**：抽 100 条让 LLM 判一遍，算与规则 grader 的一致率（Cohen's κ）；再人工核 30 条，形成三方对照。若一致率低于 90%，需要重估所有历史数字。

问题 11｜recovery 分析只有 48 个样本

- **判断**：成立。missing_reason_corrected 只有 n=4，Fisher 精确检验 4/4 vs 0/4 得 p≈0.029，勉强显著，但样本量太小，不足以支撑强结论。
- **修复**：把每个错误模式的样本量扩到 n≥20，再下结论。当前唯一让我对它有点信心的是：该结果在两个独立的 DPO 运行（β=0.1 与 β=0.5）中复现了。

问题 14｜README / baseline_diagnosis / clarify_boundary 与代码不一致

- **现状**：部分成立。我已给两份模板文档加了现状指引，但 README 的实验清单仍是旧的（4 个实验，而实际跑了 7 组）。
- **修复**：统一文档与代码的实验清单；写一个脚本自动校验「文档里提到的实验名是否都存在于 experiments/」，把这个不一致变成测试。

问题 15｜缺少 W&B / MLflow 等实验追踪

- **判断**：成立，但优先级低。当前用 train_log.jsonl + train_monitor.py 能出健康度报告，缺的是跨实验可比性与可视化。
- **修复**：接入 W&B（约 30 分钟），或至少把 7 组实验的曲线汇总成一张对照图。

问题 16｜版本、随机种子、shuffle 的可复现性

- **现状**：部分成立。已固定随机种子、记录环境版本（torch 2.5.1+cu124、transformers 4.49.0、trl 0.13.0、peft 0.21.2），但从未做「同配置重跑两次、比对结果」的复现性验证。
- **修复**：用同一配置重跑一次 sft_v3，比对 accuracy 与逐任务结果，给出复现性误差范围。

问题 19｜1.5B + 100 任务 + 3090 规模太小，没试 7B/13B

- **判断：**成立。当前结论都是在 1.5B 上得到的，「对比信号损害任务能力」这个结论能否外推到更大模型，未知。
- **修复：**跑一组 7B 的 SFT + DPO 对照。这是性价比最高的一条扩展性验证（约 3 小时 GPU）。

问题 20｜缺基线与方法对比（Functionary / ToolLLM、IPO/KTO/ORPO）

- **判断：**成立。完全没有与外部方法对比，也只在 DPO 一个偏好优化算法上做过实验。
- **修复：**至少补一组 ORPO 或 KTO（它们不需要 reference model，能验证「崩塌是否源于 DPO 的 reference 机制」），以及在报告里明确声明未与外部 tool-calling 模型对比。

2.3 需要更多信息才能判断的问题

以下四条我在 PDF 里只能读到部分 ASCII 片段，推断置信度较低，需要专家提供原文：

编号	我推断的内容	置信度	需要的原文
4	chosen/rejected 构造（拒答类样本）	中	该条完整描述
7	数据里 35% / 65% 的比例、JSON 相关	中	该条完整描述
12	agent 评测的 token / 轮数口径	中	该条完整描述
13	dpo_from_sft 与 dpo_format/recovery 的实验，mock 混入	中	该条完整描述

§3 我自己认为还需要做的事（专家未提及）

3.1 结论强度与证据强度不匹配

我在报告里把几条弱证据写成了强结论。逐条列出并降级：

现有表述	实际证据强度	应改成
「对比信号能编码否定性约束」	n=4 × 1 个错误模式（p≈0.029）	「在两个独立 DPO 运行中复现的初步证据，样本量需扩大」
「DPO 不如 SFT」	从未做显著性检验	「观测到下降，显著性待检验」
「agent 成功率 100%」	39 个任务，不含最弱的 flight_search	「在与 agent 循环相关的四个类别上 100%」
「seen/unseen 泛化指标」	seen 反而比 unseen 低 16.3pp，构成均衡，原因未明	「该维度不可用于泛化结论」

3.2 评测效度：单一判据的风险

整个项目的所有数字都来自一个规则评分器。这个项目已经出现过两次「评分口径问题」：

- 错误分类器误标 100 条（json_broken 实为「不调工具」）
- extra_fields 没有 schema 白名单，让报告冤枉模型 42 次（虽不影响打分，但误导了失败归因）

这两次都是我自己发现的，但**没有任何机制能在下次自动发现同类问题**。加 LLM-based grader 对照正是为了建立第二个独立判据。

3.3 我的错误模式（自我复盘）

回顾这个项目，我犯的错有一个共同模式：

错误	我的推断	实际情况
Agent 播种逻辑	「多给信息更公平」	泄露答案，成功率差 41pp
污染检查	比对 task_id 即可	字段为空导致假阴性，白跑一轮 GPU
extra_fields	它出现在错误报告里，所以影响打分	只影响诊断标签，不改 passed
logps/chosen	它稳定，所以模型健康	accuracy 崩了 33.75pp
95% 主结果	数字好看，先往下做	污染，需推翻重做

共同点：我把「看起来合理」当成了「已验证」。专家的问题清单本质上是在同一个方向上追问——每一个结论，你有没有独立的判据？

§4 执行计划

4.1 第一批：我自己可完成，不需要 GPU（约 5 小时）

序	任务	产出	预计
1	重构消融报告：主表只用干净数据，污染数字下沉附录	ablation_report.md v2	30 分钟
2	写 paired_significance.py：McNemar + 配对 bootstrap + 功效分析	统计报告（含 MDE）	40 分钟
3	写 measure_kl_drift.py：真实 KL(π_θ||π_ref) 监控	KL 漂移脚本	60 分钟
4	写 prompt_engineering.py：不改权重的 prompt 对照	对照实验脚本	30 分钟
5	统一文档与代码的实验清单，加自动校验测试	一致性测试	40 分钟
6	把所有弱结论按 §3.1 降级，补「净负贡献」的明确判断	报告与面试稿修订	40 分钟
7	接入 W&B（或汇总 7 组曲线为一张对照图）	实验追踪	30 分钟

4.2 第二批：需要租用 GPU（约 3.5 小时，≈ ¥6）

序	任务	目的	预计
8	超参对齐的 DPO：并从 sft_v3 出发，lr = 5e-5 与 1e-4 各一次	排除「lr 不可比」这一解释	40 分钟
9	β 扫描 [0.02, 0.05, 0.1, 0.2]，全部从 sft_v3 出发	β 的受控比较（替代当前不可比的 2 点）	80 分钟
10	任务集扩到 400 任务/组：baseline + sft_v3	CI 从 ±10pp 压到 ±5pp，让主结果更稳	60 分钟
11	prompt engineering 对照（不改权重，只改 prompt）	验证「DPO 想要的效果能否由 prompt 拿到」	20 分钟
12	真实 KL 漂移测量（用第 3 项的脚本）	给出 π_θ 与 π_ref 的真实分布距离	10 分钟

4.3 第三批：时间允许（约 4.5 小时，≈ ¥8）

序	任务	目的	预计

13	agent 评测补 flight_search / weather 的多轮变体	消除「100% 只覆盖易类别」的质疑	我 60 分钟 + GPU 15 分钟
14	LLM-based grader 对照 + 人工核 30 条	建立第二个独立判据，给出一致率 κ	我 60 分钟 + GPU 30 分钟
15	7B 模型 SFT + DPO 对照	验证结论能否外推到更大模型	约 3 小时
16	同一配置重跑 sft_v3 一次	给出复现性误差范围	30 分钟
17	补一组 ORPO 或 KTO	验证崩塌是否源于 DPO 的 reference 机制	60 分钟

4.4 时间与成本合计

批次	**我的工时**	**GPU 工时**	**成本（3090 ¥1.68/h）**
第一批（无 GPU）	约 5 小时	0	¥0
第二批	0	约 3.5 小时	约 ¥6
第三批	约 2 小时	约 5.5 小时	约 ¥9
合计	约 7 小时	约 9 小时	约 ¥15

§5 需要确认的三件事

#	需要确认	为什么重要
1	问题清单的原文（Word / Markdown / 邮件皆可）	PDF 的中文已丢失，我的问题描述是推断的；第 4、7、12、13 条置信度只有「中」，可能误读
2	第三批（7B 对照、ORPO/KTO、agent 覆盖补齐）是否要做	会显著增加 GPU 成本与时间；不做的部分我会在报告里明确列为「已知局限」而不是省略
3	任务集扩到 400 任务是否接受「主结果数字会变」	扩集后 baseline 与 sft_v3 都会重新测，现有 83.00% 这个数字会被新数字替代

§6 我不打算做的事（明确声明）

- 不为了好看而保留任何受污染的数字：三组污染实验（sft_only / dpo_joint / dpo_from_sft）的全部数字将从主表移出。
- 不把「DPO 有正面价值」写成结论：当前证据是净负贡献，除非 β 扫描 + prompt 对照 + 条件化偏好数据能翻盘。
- 不声称 agent 评测覆盖了模型整体能力：它只覆盖 39 个多轮任务中的四类。
- 不把 seen/unseen 当作泛化指标：该维度已证明不可用。

一句话总结：这个项目现在最缺的不是新实验，而是把已有结论的证据强度与表述强度对齐——以及在每个结论上建立独立判据。